第2章 File and DataTable

大數據分析

- R/Python/Julia/SQL程式設計與應用 (R/Python/Julia/SQL Programming and Application)
- 資料視覺化 (Data Visualization)
- 機器學習 (Machine Learning)
- 統計品管 (Statistical Quality Control)
- 最佳化 (Optimization)

李明昌博士

https://www.youtube.com/@alan9956

http://rwepa.blogspot.com/

alan9956@gmail.com

大綱

1. Orange 使用
2. 內建範例 File and Data Table
3. 散佈圖 (Scatter Plot)
4. 盒鬚圖 (Boxplot)
5. Q & A

1. Orange 使用

New

- 選取 New 按鈕

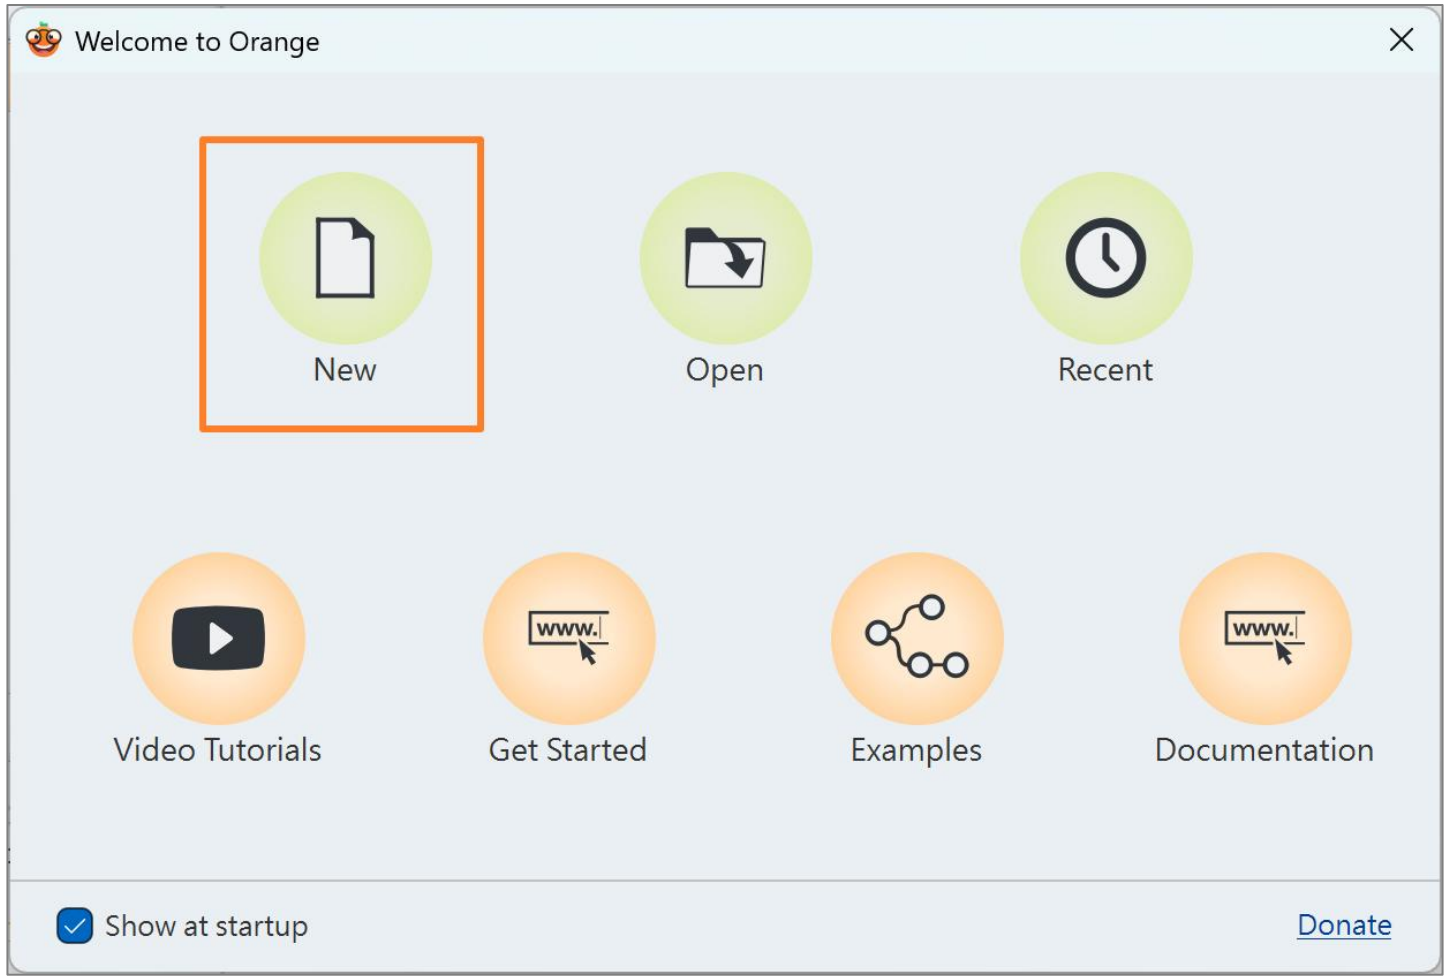
Welcome to Orange
New
Open
Recent
Video Tutorials
Get Started
Examples
Documentation
Show at startup
Donate

New 初始畫面

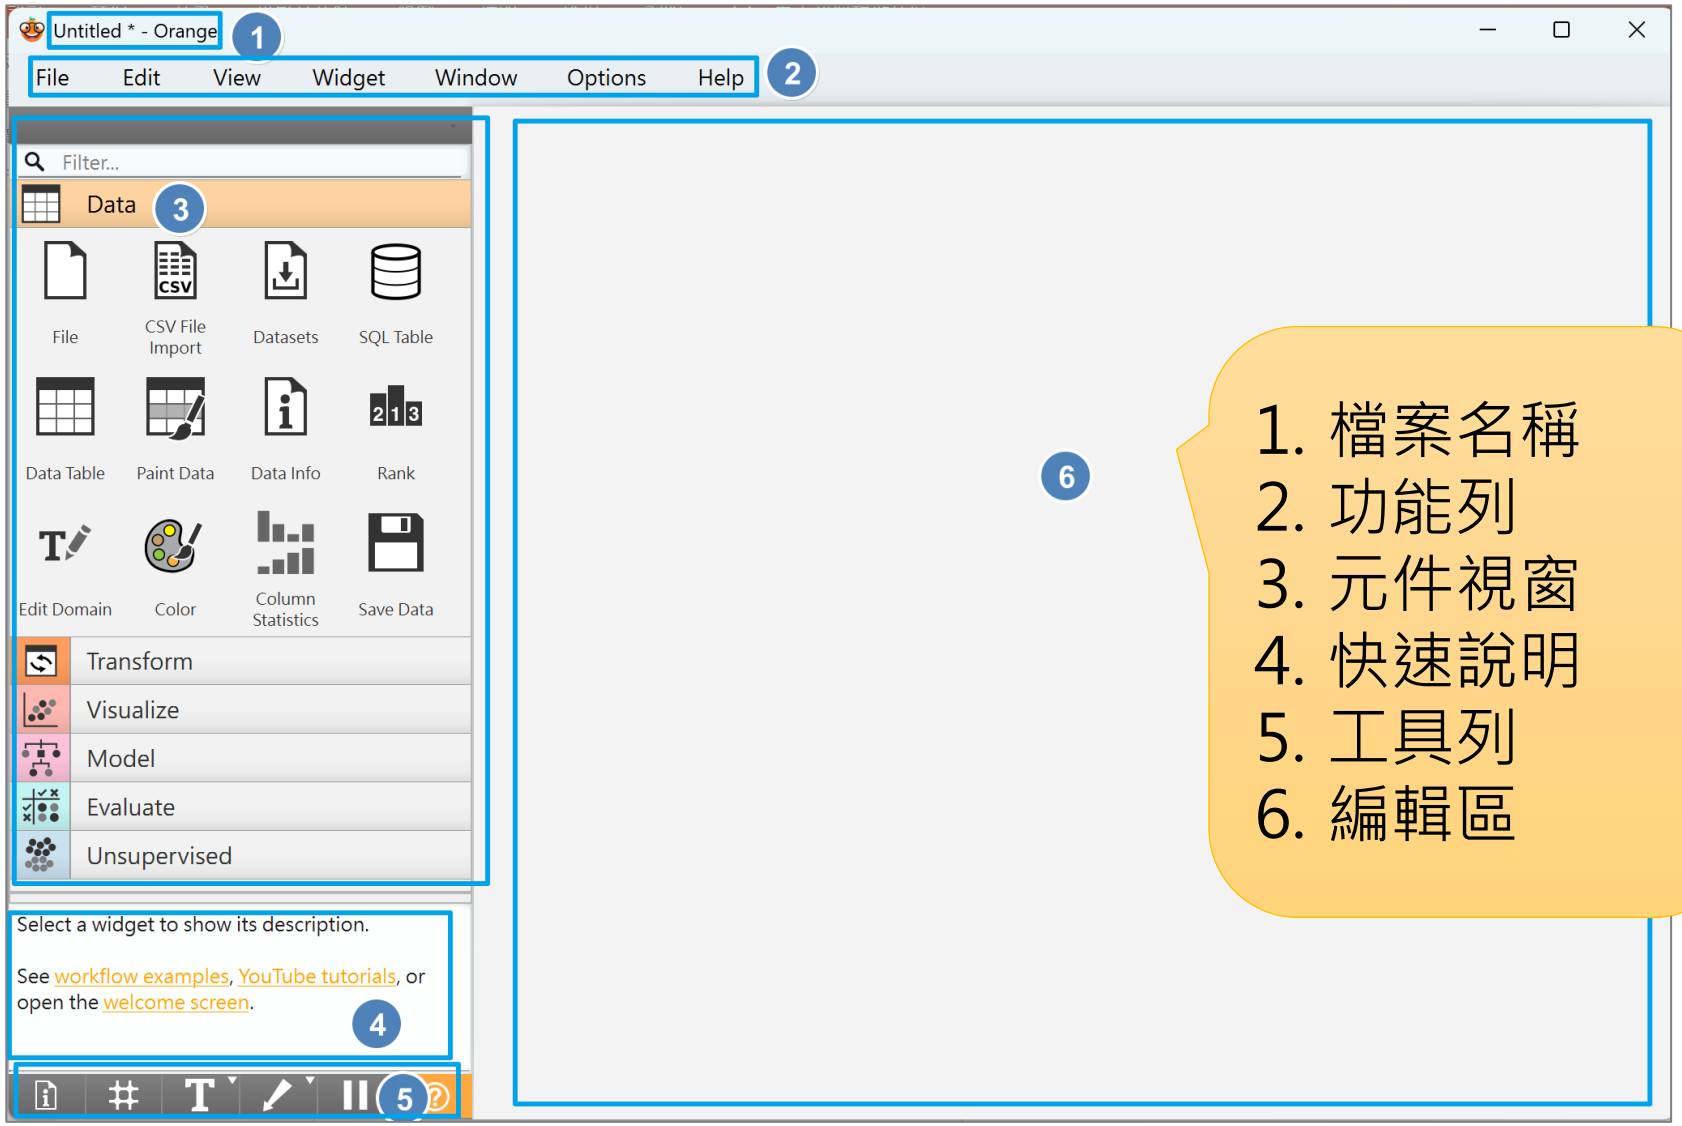

1. 檔案名稱
2. 功能列
3. 元件視窗
4. 快速說明
5. 工具列
6. 編輯區

元件視窗 (1/3)

資料元件

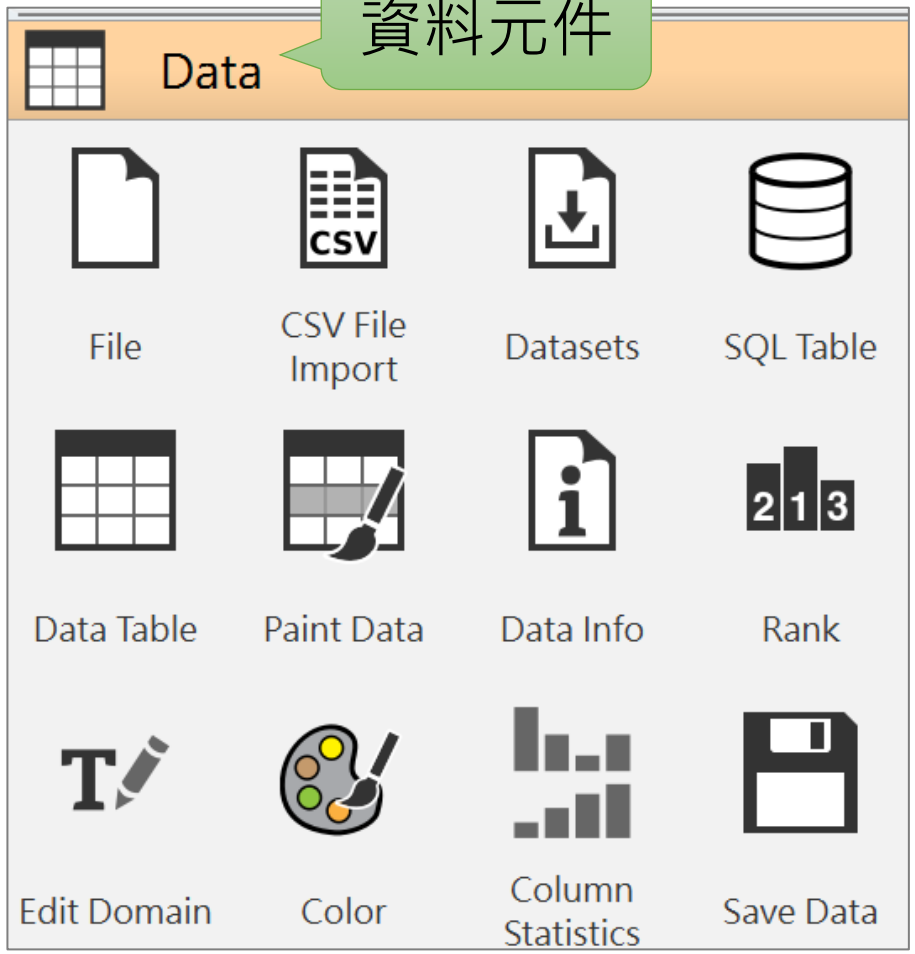

轉換元件

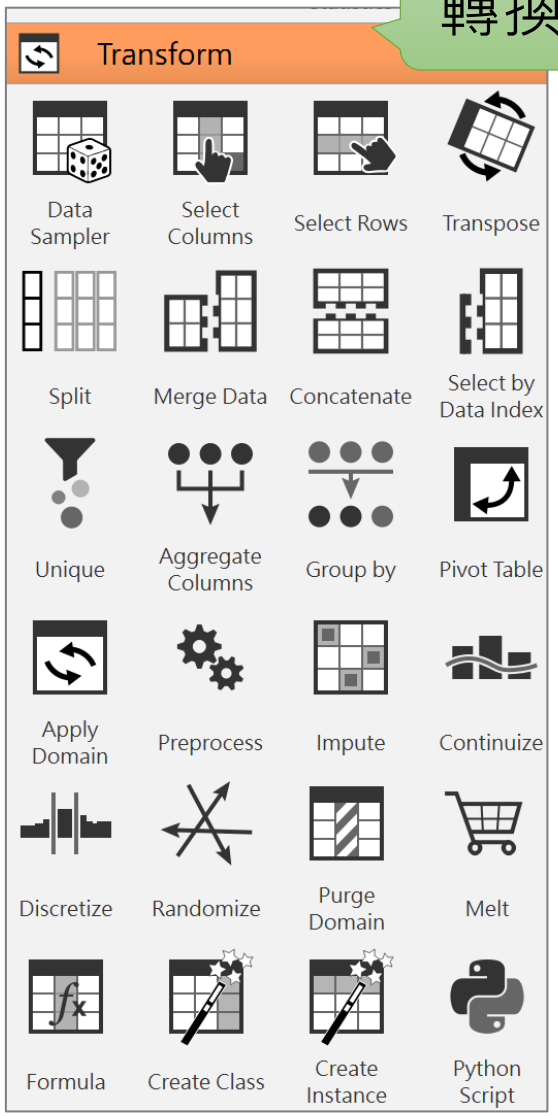

元件視窗 (2/3)

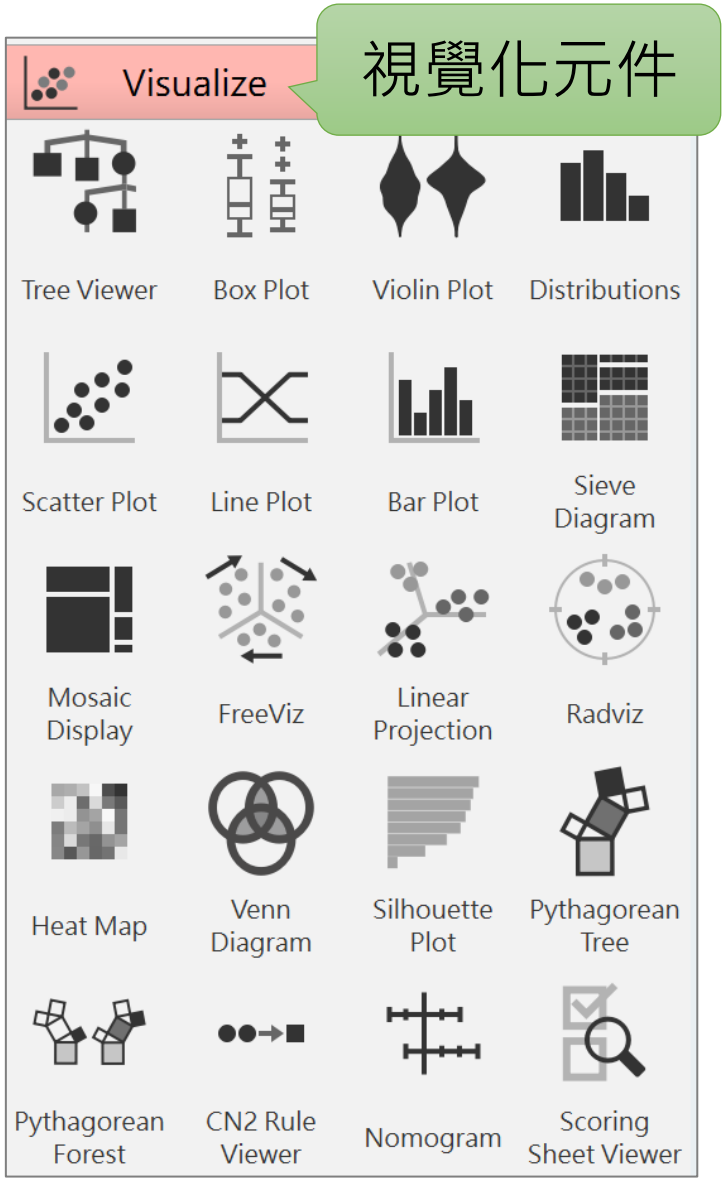
視覺化元件
Visualize
Tree Viewer
Box Plot
Violin Plot
Distributions
Scatter Plot
Line Plot
Bar Plot
Sieve Diagram
Mosaic Display
FreeViz
Linear Projection
Radviz
Heat Map
Venn Diagram
Silhouette Plot
Pythagorean Tree
Pythagorean Forest
CN2 Rule Viewer
Nomogram
Scoring Sheet Viewer

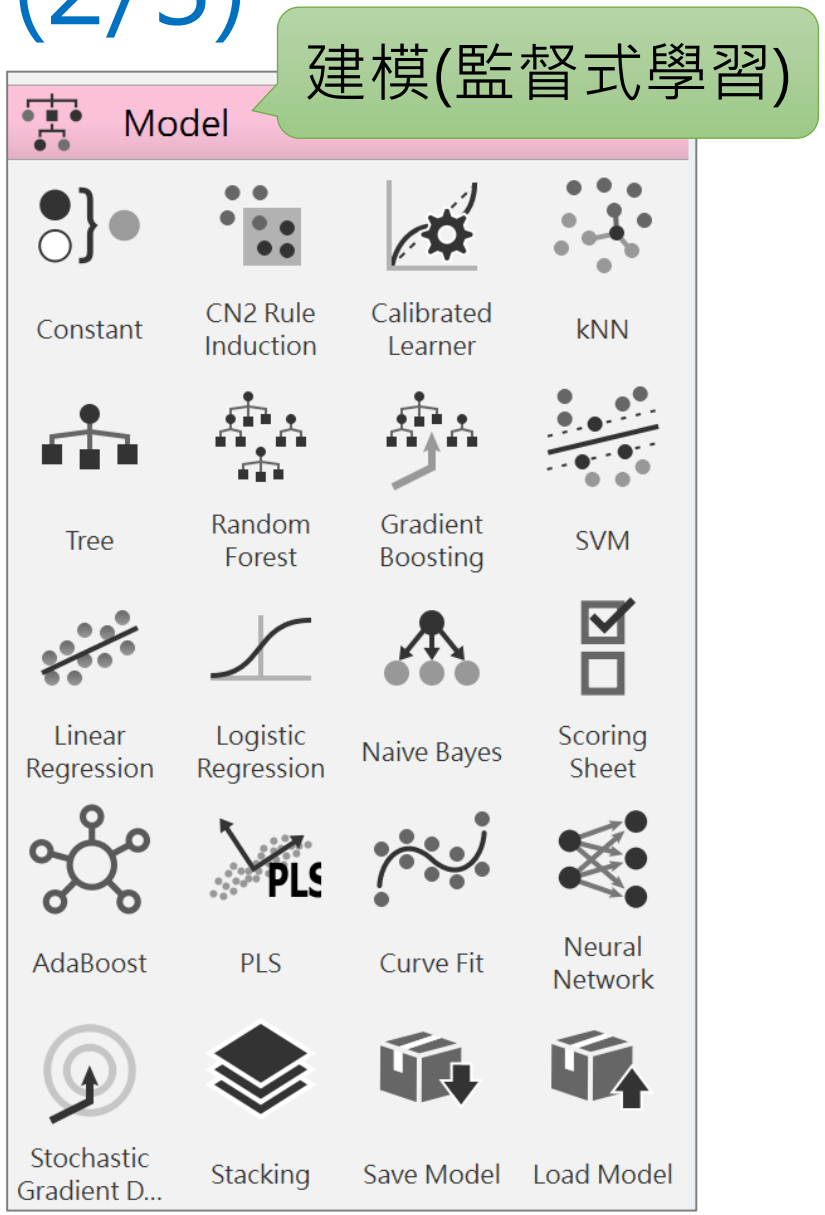
建模(監督式學習)
Model
Constant
CN2 Rule Induction
Calibrated Learner
kNN
Tree
Random Forest
Gradient Boosting
SVM
Linear Regression
Logistic Regression
Naive Bayes
Scoring Sheet
AdaBoost
PLS
Curve Fit
Neural Network
Stochastic Gradient D...
Stacking
Save Model
Load Model

元件視窗 (3/3)

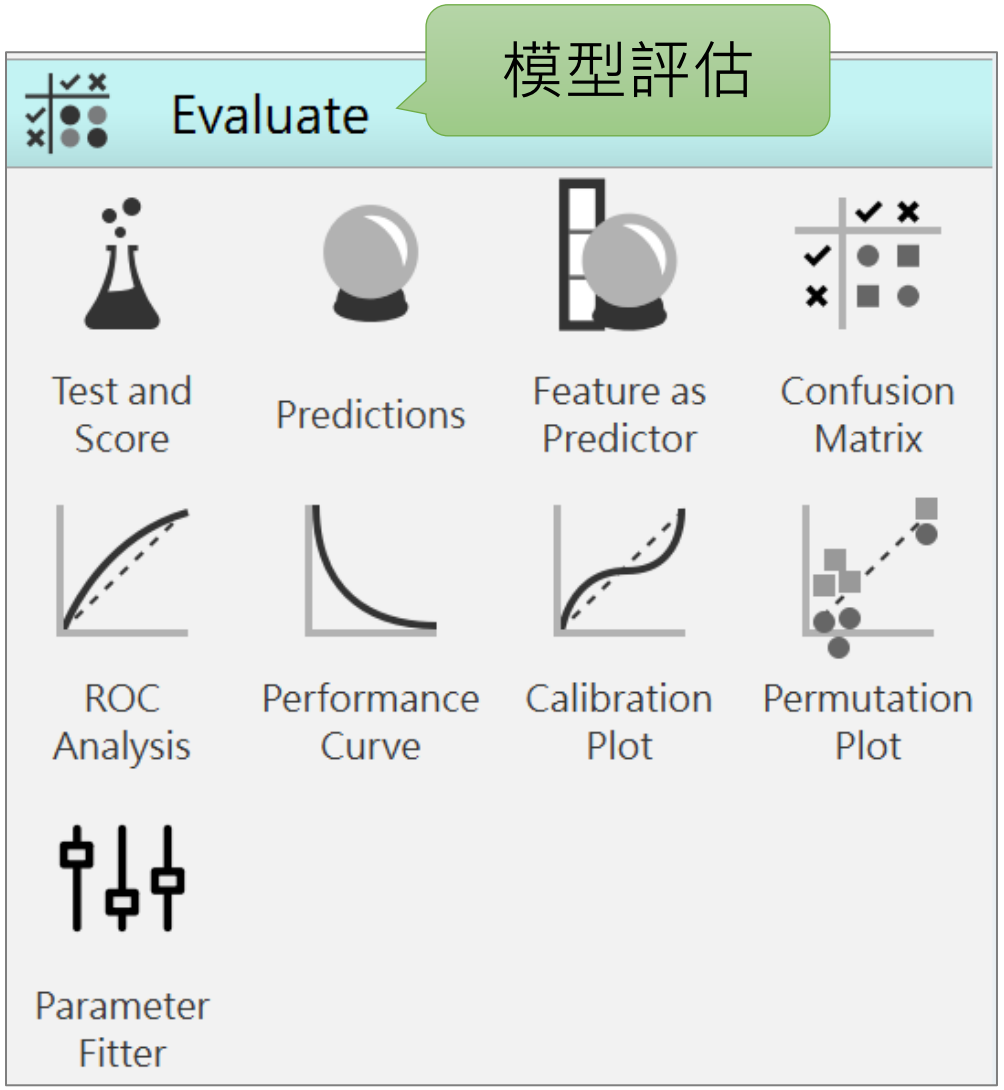
模型評估
Evaluate
Test and Score
Predictions
Feature as Predictor
Confusion Matrix
ROC Analysis
Performance Curve
Calibration Plot
Permutation Plot
Parameter Fitter

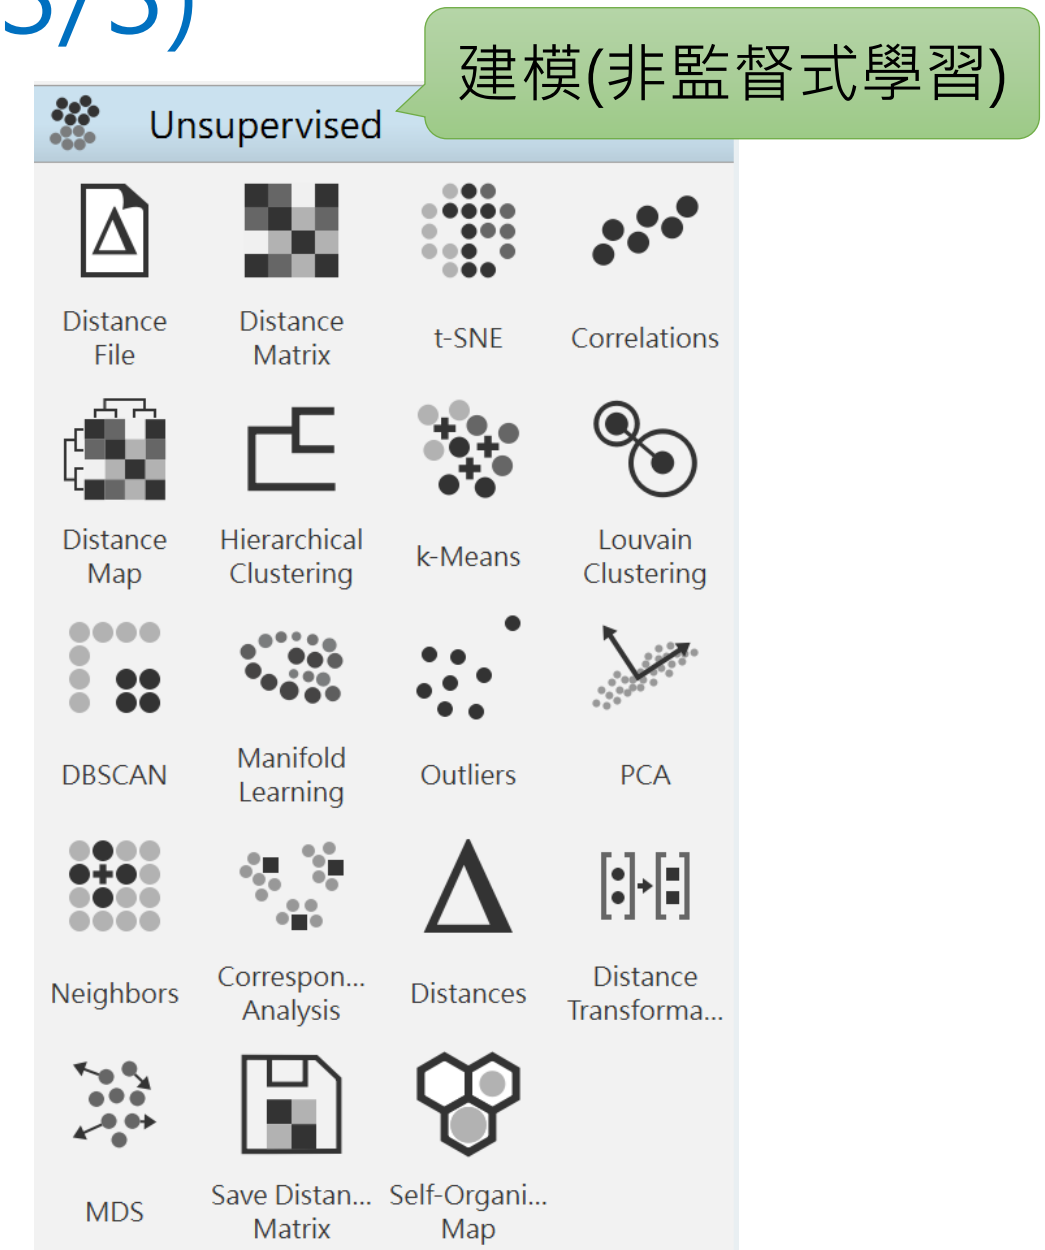
建模(非監督式學習)
Unsupervised
Distance File
Distance Matrix
t-SNE
Correlations
Distance Map
Hierarchical Clustering
k-Means
Louvain Clustering
DBSCAN
Manifold Learning
Outliers
PCA
Neighbors
Correspon... Analysis
Distances
Distance Transforma...
MDS
Save Distan... Matrix
Self-Organi... Map

2. 內建範例 File and Data Table

選取 Examples

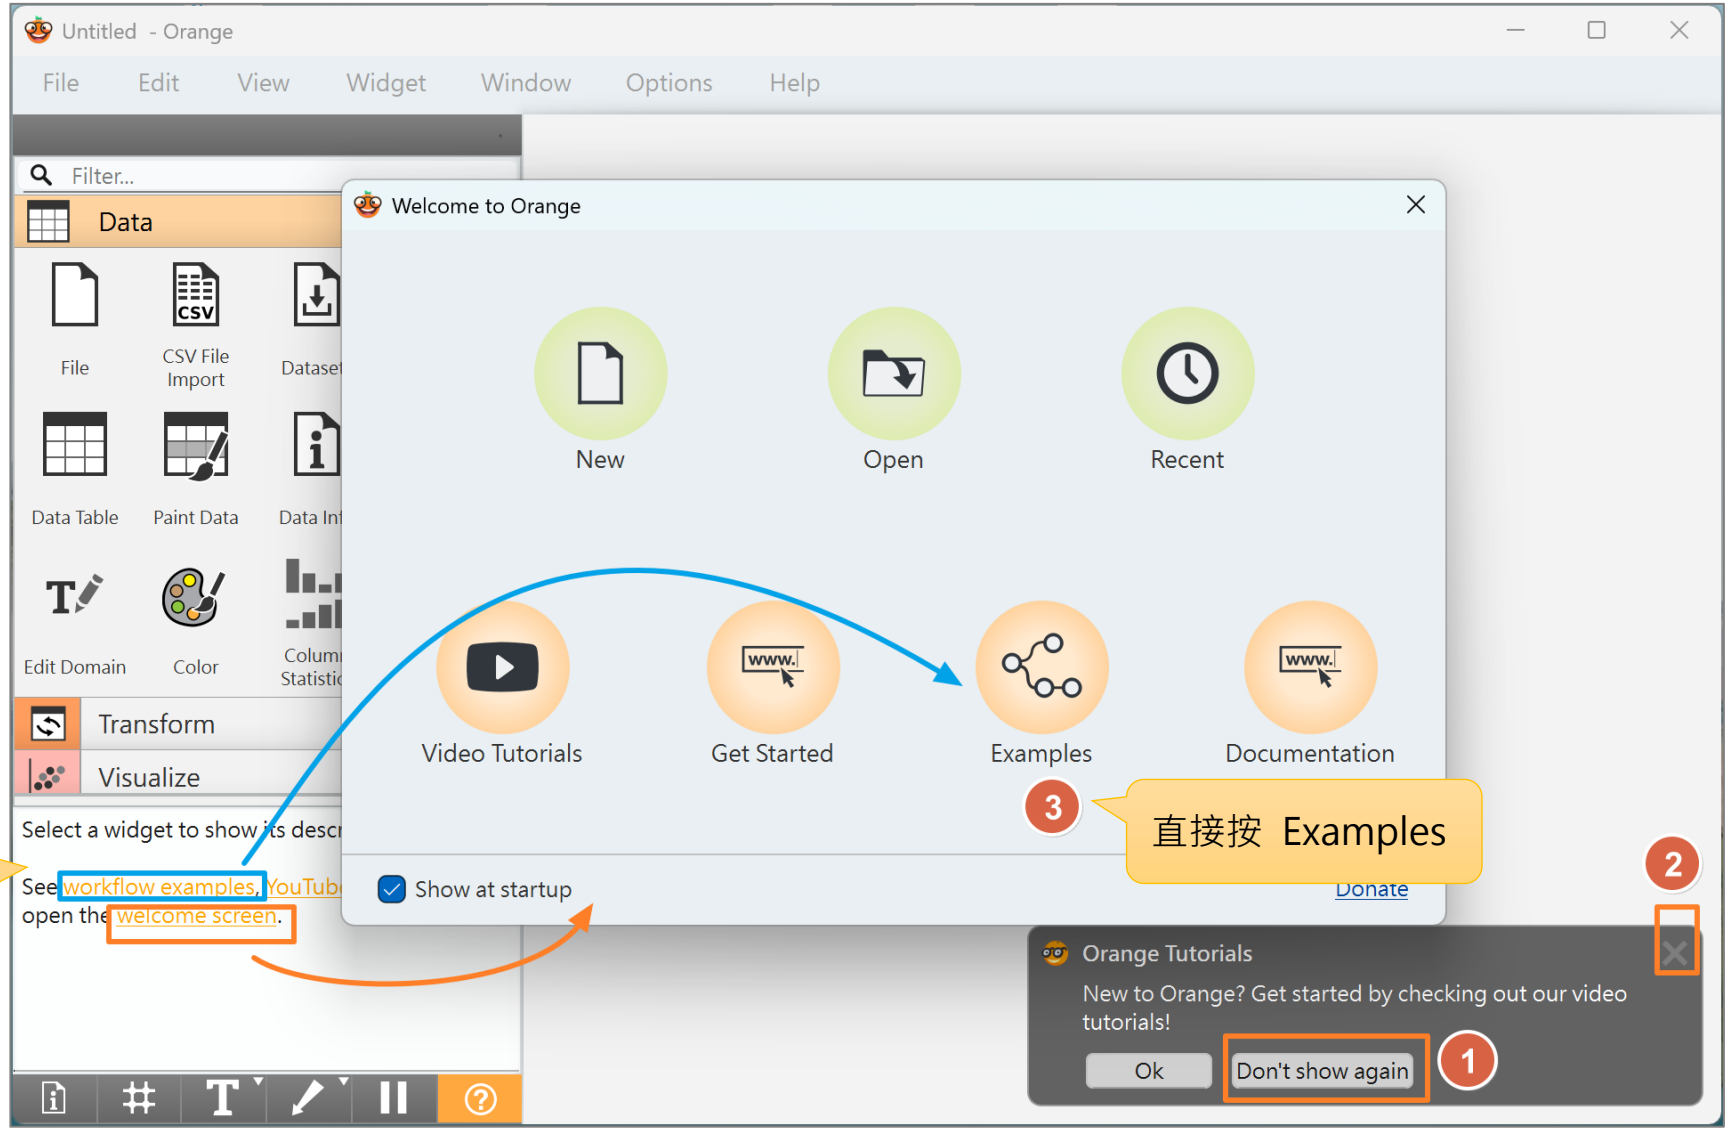

選取 左下角 workflow examples

直接按 Examples

Example Workflows

- 選取 [File and Data Table] → [Open]

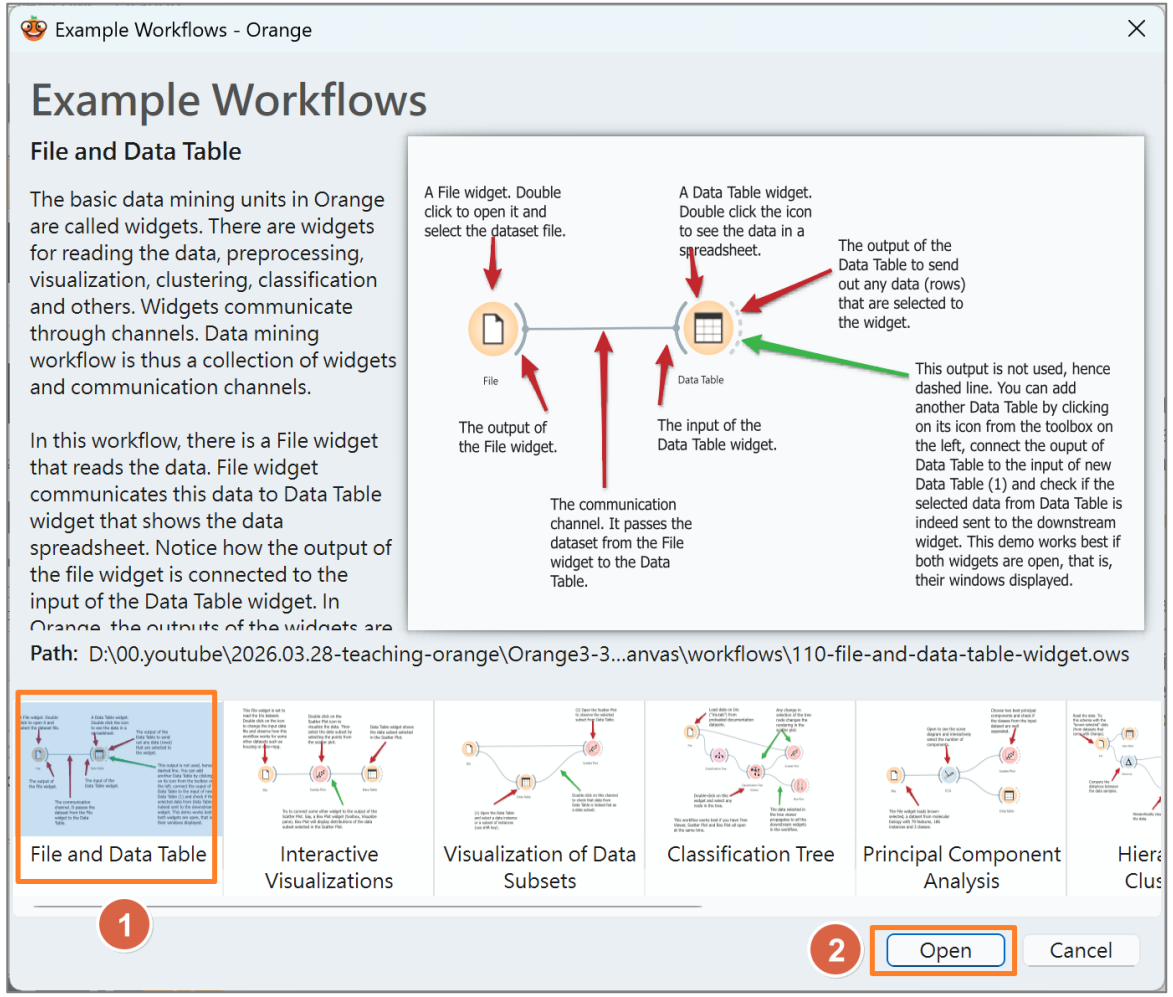

Orange 開啟範例畫面

- File \ Save As

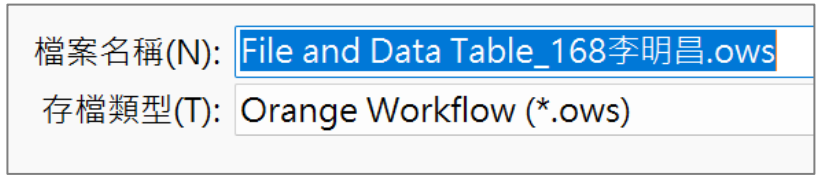

學號姓名

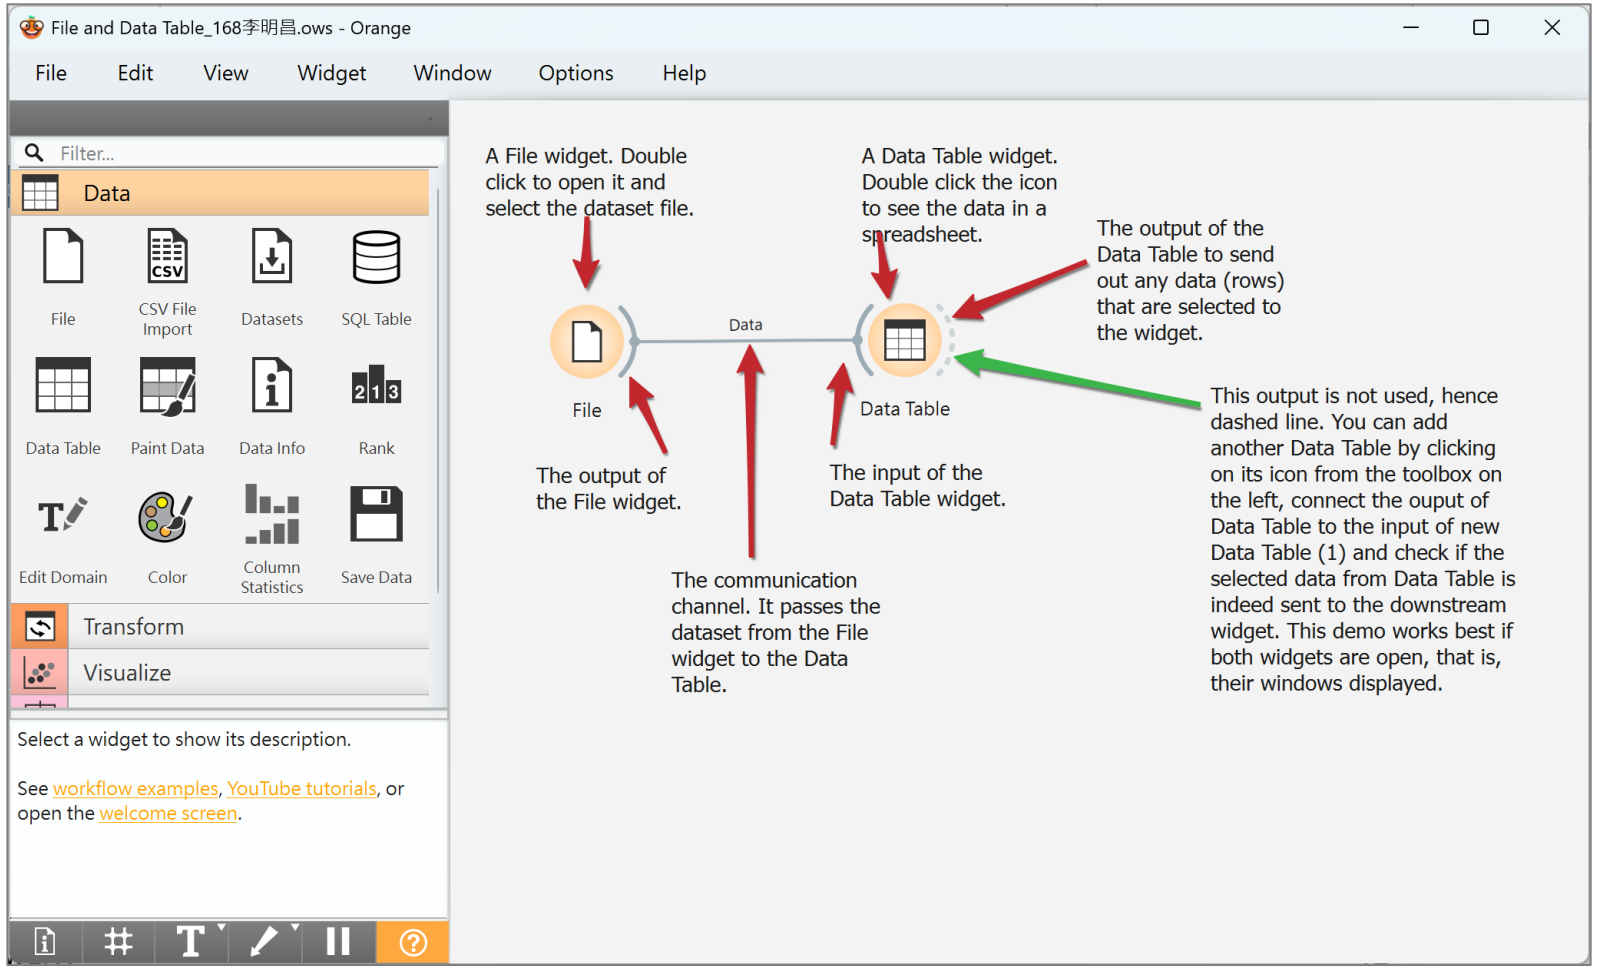

File 元件 – 檔案

載入資料

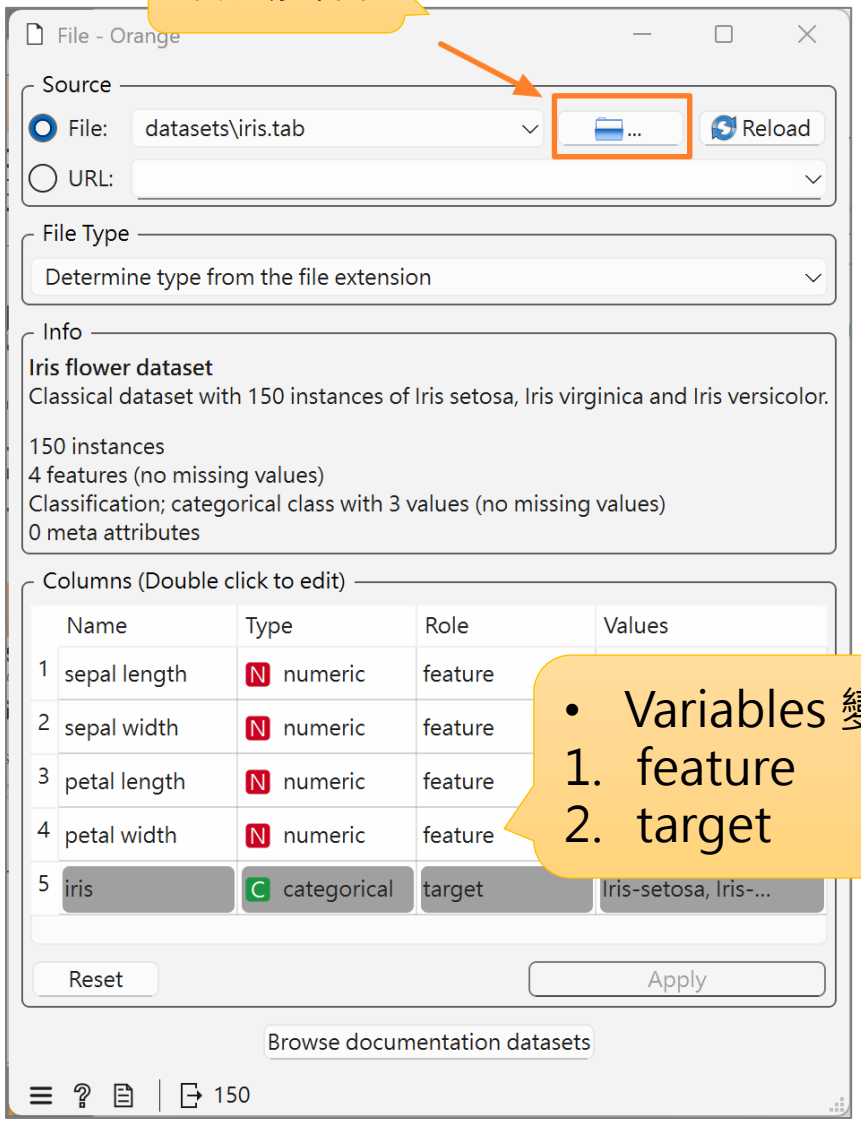

- Variables 變數:
1. feature : 自變數
2. target : 反應變數

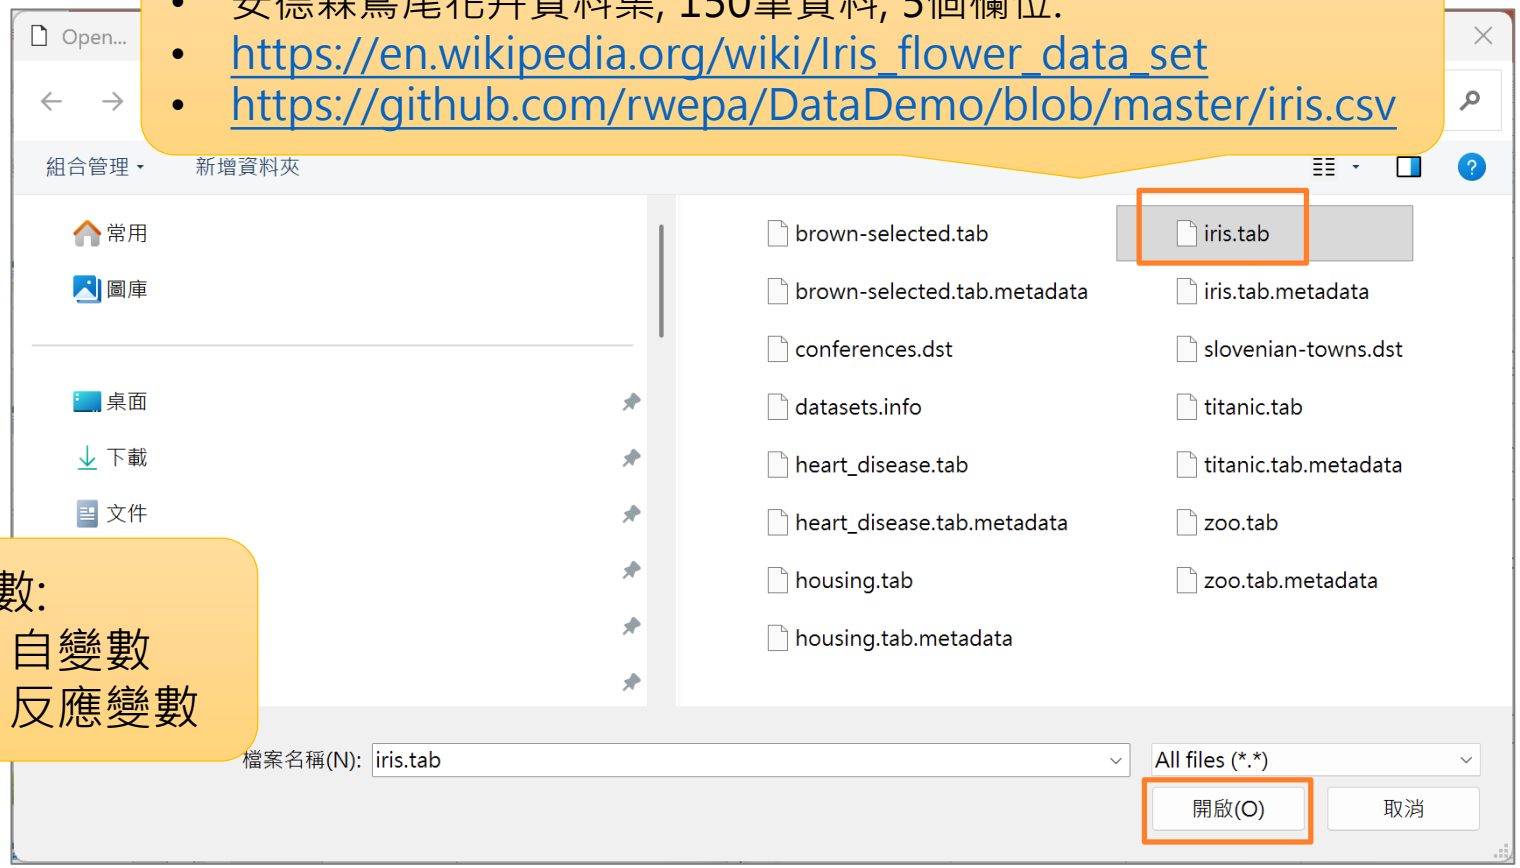

- 安德森鳶尾花卉資料集, 150筆資料, 5個欄位.
- https://en.wikipedia.org/wiki/Iris_flower_data_set
- https://github.com/rwepa/DataDemo/blob/master/iris.csv

變數: https://github.com/rwepa/DataDemo?tab=readme-ov-file#variables

Data Table 元件 – 資料表格

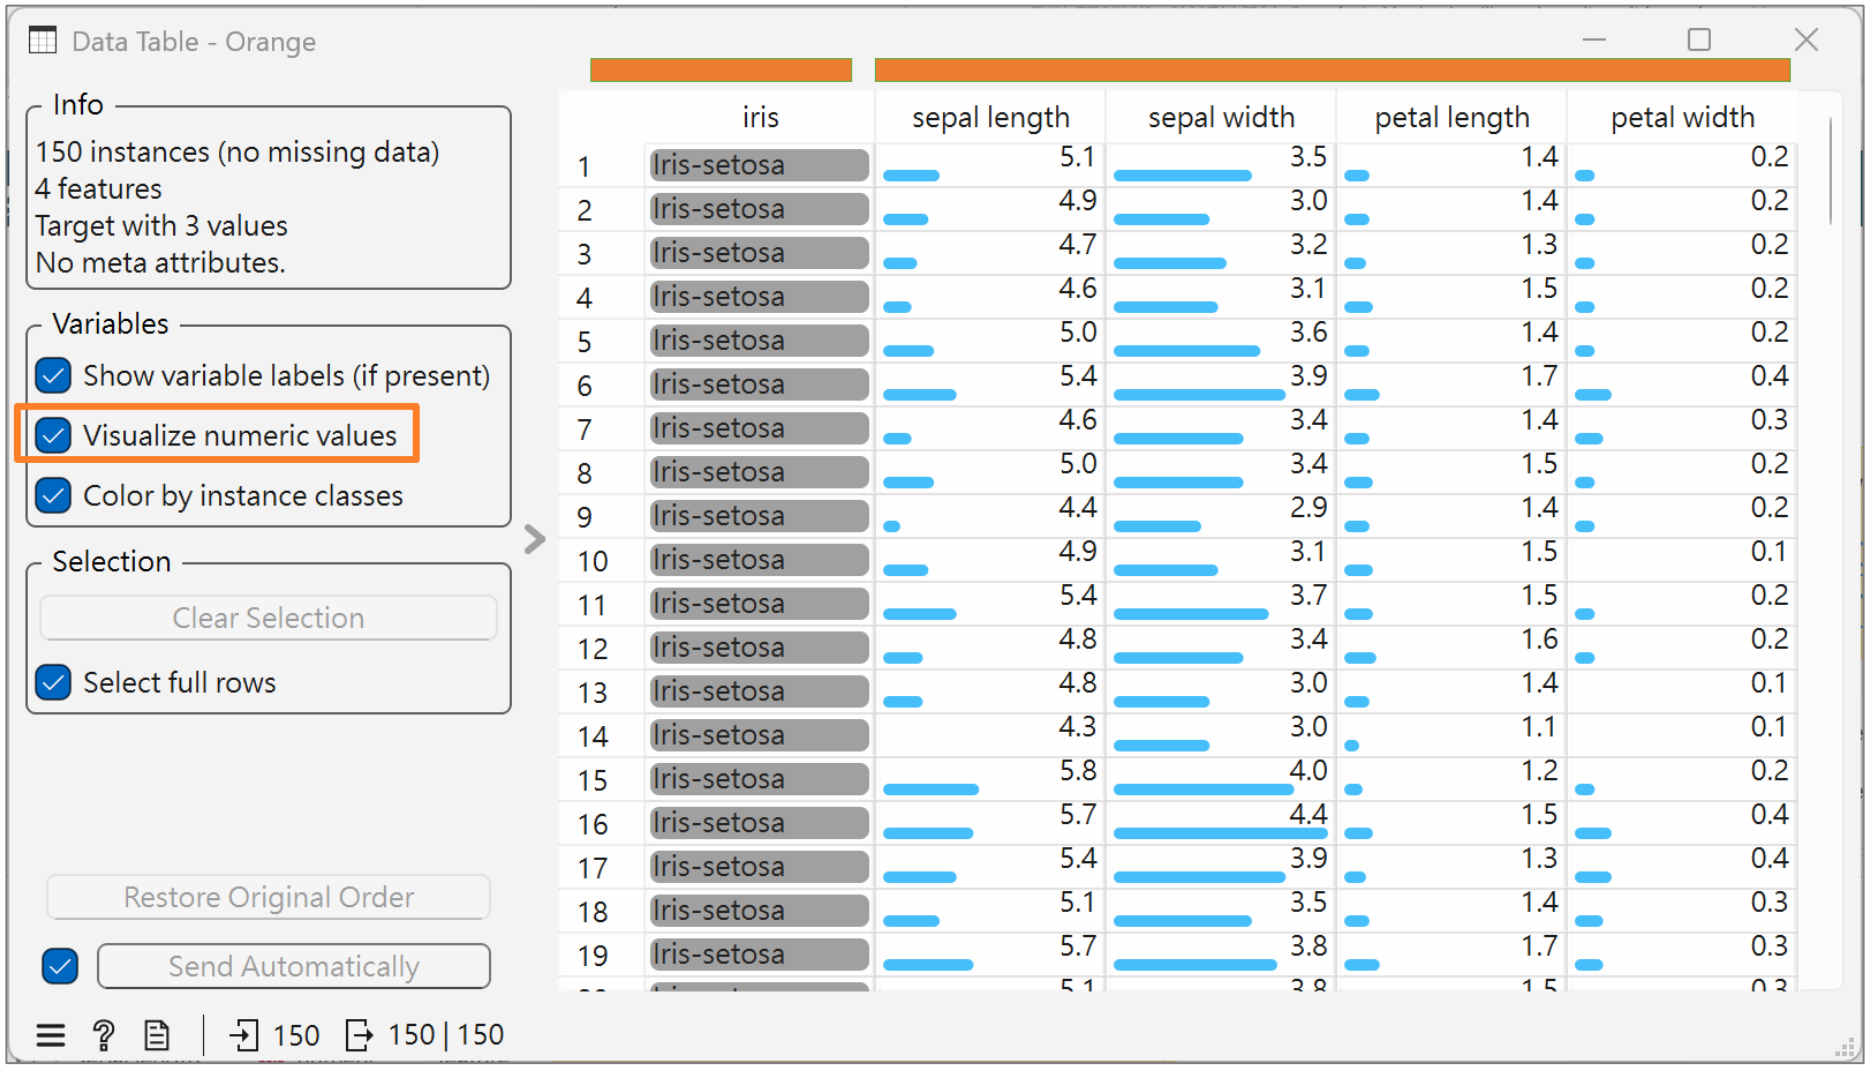

	iris	sepal length	sepal width	petal length	petal width
1	Iris-setosa	5.1	3.5	1.4	0.2
2	Iris-setosa	4.9	3.0	1.4	0.2
3	Iris-setosa	4.7	3.2	1.3	0.2
4	Iris-setosa	4.6	3.1	1.5	0.2
5	Iris-setosa	5.0	3.6	1.4	0.2
6	Iris-setosa	5.4	3.9	1.7	0.4
7	Iris-setosa	4.6	3.4	1.4	0.3
8	Iris-setosa	5.0	3.4	1.5	0.2
9	Iris-setosa	4.4	2.9	1.4	0.2
10	Iris-setosa	4.9	3.1	1.5	0.1
11	Iris-setosa	5.4	3.7	1.5	0.2
12	Iris-setosa	4.8	3.4	1.6	0.2
13	Iris-setosa	4.8	3.0	1.4	0.1
14	Iris-setosa	4.3	3.0	1.1	0.1
15	Iris-setosa	5.8	4.0	1.2	0.2
16	Iris-setosa	5.7	4.4	1.5	0.4
17	Iris-setosa	5.4	3.9	1.3	0.4
18	Iris-setosa	5.1	3.5	1.4	0.3
19	Iris-setosa	5.7	3.8	1.7	0.3

3. 散佈圖 (Scatter Plot)

散佈圖簡介

- 主要用來觀察兩個變數之間的關係。
- 散佈圖是將每一筆資料以「點」的形式畫在座標平面上：
  - 橫軸（X軸）：一個變數
  - 縱軸（Y軸）：一個變數
  - 每個點代表一筆資料（x, y）
  - X軸、 Y軸是二維資料，可以加上不同點的大小、顏色。
  - 範例：X軸：廣告費， Y軸：銷售額

散佈圖功能

- 觀察變數之間的關係。
  - 📈 正相關（Positive Correlation）：X增加，Y也增加。
  - 📉 負相關（Negative Correlation）：X增加，Y減少。
  - ➖ 無相關（No Correlation）：沒有明顯規律。
- 找出異常值，暨明顯偏離其他點的資料。
- 發現資料趨勢
  - 例：曲線關係（非線性）、分群（clusters）、週期性變化。
- 加上趨勢線（迴歸線）
  - 例：數值預測、建立線性模型。
- 注意：關係性不能證明因果。

關係 ≠ 因果

散佈圖企業應用

部門	正相關	負相關	無相關
生產	• 設備投資 ↑ ， 產量 ↑ • 生產自動化程度 ↑ ， 生產效率 ↑	• 生產成本 ↑ ， 利潤 ↓ • 設備故障率 ↑ ， 產量 ↓	• 廠所在地天氣 vs 生產效率（通常無直接關係）
銷售	• 廣告預算 ↑ ， 銷售額 ↑ • 社群曝光 ↑ ， 客戶數 ↑	• 商品價格 ↑ ， 銷量 ↓ • 客訴數 ↑ ， 品牌好感 ↓	• Logo顏色 vs 銷售額（通常無直接關係）
人力	• 員工培訓時數 ↑ ， 工作績效 ↑ • 員工滿意度 ↑ ，留任率 ↑	• 工作壓力 ↑ ， 員工滿意度 ↓ • 離職率 ↑ ， 組織穩定度 ↓	• 員工身高 vs 工作績效
研發	• 研發投入金額 ↑ ， 專利數 ↑ • 研發人員數 ↑ ， 新產品數 ↑	• 產品開發時間 ↑ ， 上市速度 ↓ • 技術複雜度 ↑ ， 開發效率 ↓	• 辦公室裝潢風格 vs 技術突破數
財務	• 營收 ↑ ， 利潤 ↑（正常情況） • 現金流 ↑ ， 投資能力 ↑	• 負債比率 ↑ ， 財務穩定度 ↓ • 成本 ↑ ， 淨利 ↓	• 辦公室樓層 vs 股價

Scatter Plot 元件 – 散佈圖

實作練習

- 步驟1 新增 Scatter Plot 元件
- 步驟2 將Data Table 連接線至 Scatter Plot
- 步驟3 點選 Scatter Plot

1. 散佈圖區分幾區?
2. 資料有什麼樣式?

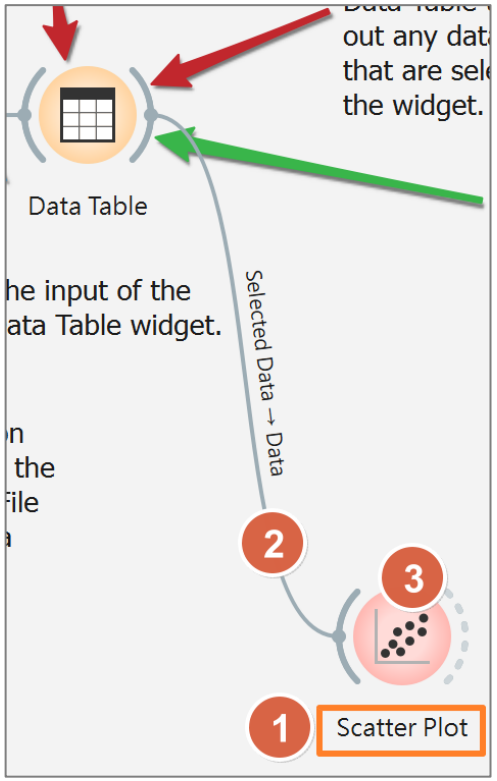

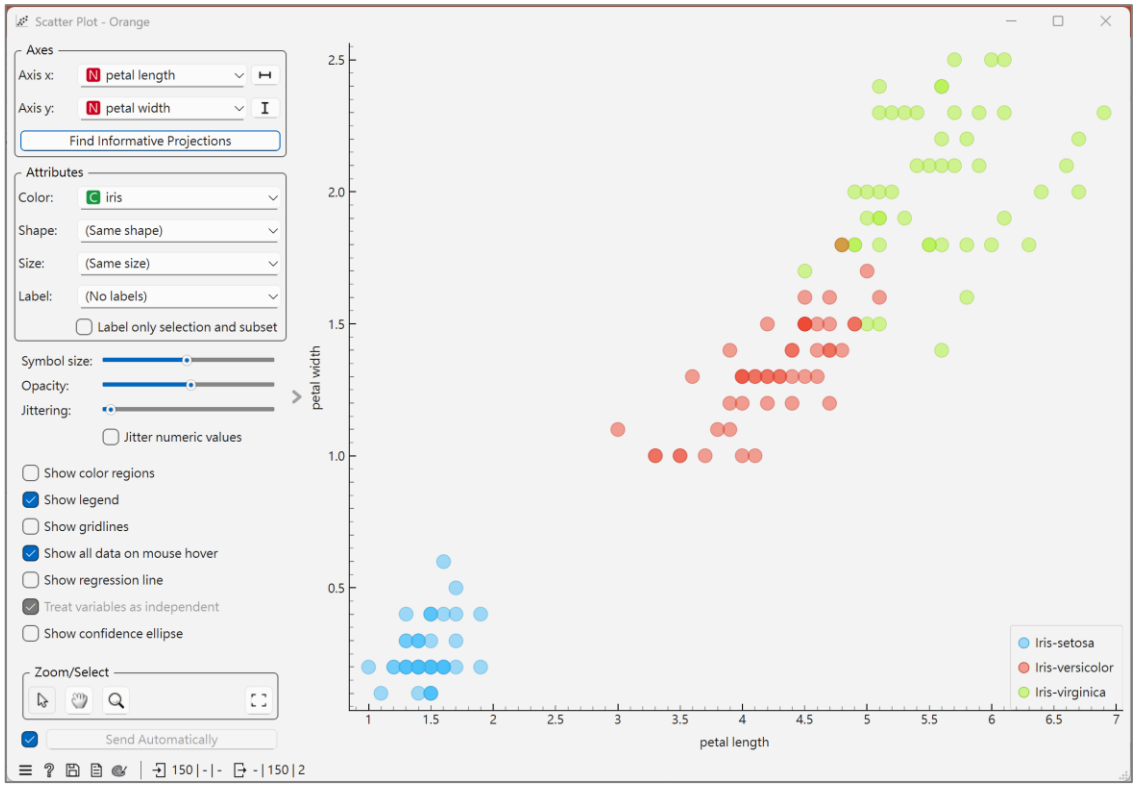

4. 盒鬚圖 (Boxplot)

盒鬚圖簡介

- 盒鬚圖是一種用來描述資料分布的圖表。
- 盒鬚圖特別適合了解資料集中點。
- 資料分散程度並找異常值（離群值，Outliers）。

集中
分散
異常

盒鬚圖五大數值

- 盒鬚圖主要由5個數值摘要（Five-number summary）
  1. 最小值（Min）
  2. 第一四分位數（Q_1）：有25%的資料在Q_1值以下
  3. 中位數（Median, Q_2）：有50%的資料在Q_2值以下
  4. 第三四分位數（Q_3）：有75%的資料在Q_3值以下
  5. 最大值（Max）

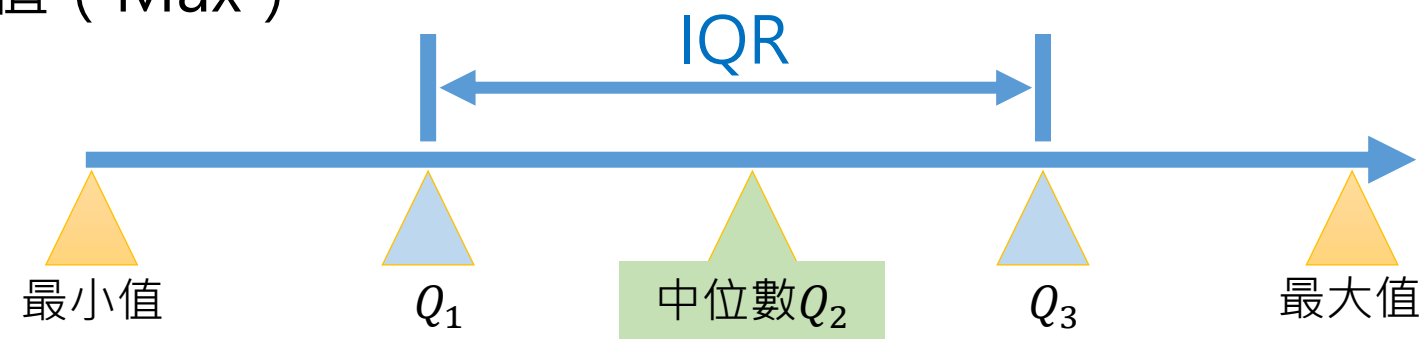

四分位距

- 四分位距（Interquartile Range，IQR）用於衡量資料「分散程度」的關鍵。
- $IQR = Q_3 - Q_1$
  - IQR大 → 資料分散
  - IQR小 → 資料集中
  - IQR 涵蓋了數據中間 50% 的部分。
- 識別異常值，資料超過以下範圍為異常值：
  - $[Q_1 - 1.5 \times IQR, Q_3 + 1.5 \times IQR]$
  - 下界$= Q_1 - 1.5 \times IQR$
  - 上界$= Q_3 + 1.5 \times IQR$
  - 異常值可能是錯誤資料或是關鍵商業訊號。
  - 異常值太多可能是風險增加的訊號。

四分位距計算

- 數值 = [12, 15, 18, 20, 22, 25, 30, 35]
- 步驟1 資料先排序 [12, 15, 18, 20, 22, 25, 30, 35]
- 步驟2 最小值=12
- 步驟3 Q_2中位數 = 第4與第5個平均值 = (20+22)÷2=21
- 步驟4 Q_1為 [12, 15, 18, 20]的中位數=(15+18)÷2=16.5
- 步驟5 Q_3為 [22, 25, 30, 35]的中位數=(25+30)÷2=27.5
- 步驟6 最大值=35
- 步驟7 異常值
  - 下界= $Q_1 - 1.5 \times IQR = 16.5 - 1.5 \times (27.5 - 16.5) = 0$
  - 上界= $Q_3 + 1.5 \times IQR = 27.5 + 1.5 \times (27.5 - 16.5) = 44$
  - 本例資料皆在上下界與上界之間，資料沒有異常值。

Box Plot 元件 – 盒鬚圖

實作練習

- 針對 sepal length 盒鬚圖結果有什麼樣式?

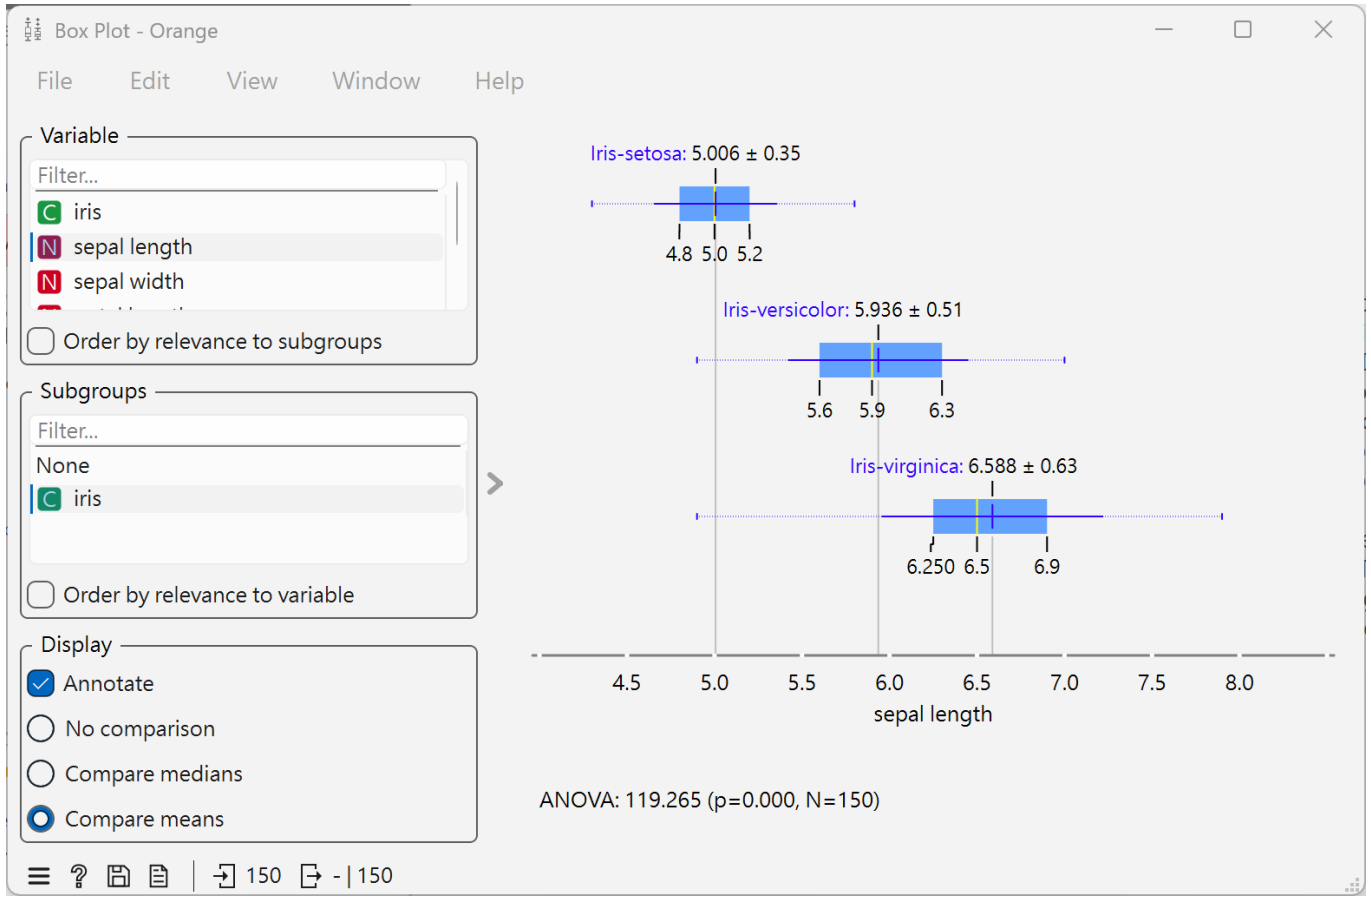

https://zh.wikipedia.org/wiki/箱形圖

謝謝您的聆聽

Q & A

李明昌

alan9956@gmail.com

http://rwepa.blogspot.tw/